


הקדמה

שיטה ומודלים



חלוקה סמולרית

למניעת
דליפת מידע
לפי זמן כדי
להבטיח
אמינות
בחיזוי.




חיזוי r30

הגדרת r30
תשואה
בטווח של 30
יום מרגע
פרסום הציוץ




איסוף והבנת
הנתונים

66,000
ציוצים ונתוני
מחיר
Yahoo



Twitter/X




ניתוח סנטימנט




חיזוי מחיר הביטקוין

פיתוח מערכת מבוססת Deep Learning לניתוח
סנטימנט מרשתות חברתיות
(X/Twitter) ככלי לזיהוי מוקדם של מצבי סיכון או
הזדמנות בשוק הביטקוין.


תוצאות



Event Study - "שור שווין"
צבירת סנטימנט לרמת ימים,
חשיפת סינגל מובהק במודל
ה Baseline בלבד.



Metric	Baseline (TF-IDF)	BiLSTM (Deep Learning)
Spread (Pump-Risk)	32.55%	12.16%
p-value	0.0002 (מובהק)	0.1185 (לא מובהק)



ברמת הציוץ הבודד, הרעש רב
מידי. קשה להבחין בין מודלים
באמצעות מדדים יבשים.

מסקנות



מניעת דליפת מידע (Data Leakage)

הסינגל בטקסט חלש ברמת ציוץ, אבל מתגלה
ברמת יום

השוואה הוגנת Baseline חזקה מוכיחה יושרה מדעית

בדיקת יציבות על דאטה גדול מחזקת שהממצאים לא
מקריים



בדיקת יציבות

הרצת Pipeline על דאטה גדול: 330,000 ציוצים
(1500 ביום) תופך שמירה על מתודולוגיה זהה.

הגדלת הדאטה שיפרה יציבות, אבל לא שינתה
את המסקנה המרכזית — הסינגל מהטקסט
קצר מוגבל ולכן נדרש מודל/דאטה עשיר יותר
כדי לראות שיפור משמעותי.

סיכום:

בנינו מערכת Deep Learning עם מתודולוגיה נקייה נגד דליפת מידע, וגילינו שהסינגל בציצים חלש ברמת ציוץ בודד אבל
מתגלה יותר טוב ברמת ימים דרך — Event Study והבדיקה על K 330 ציוצים הראתה שהתמונה יציבה והמסקנות לא
מקרייות